Tecnología para la Gestión II

Clase 10 — Repaso de `group_by()` y primeros gráficos

Francisco Villarroel Riquelme | 2026-10-14

Administración Pública · Escuela de Gobierno · Facultad de Economía y Gobierno · ADPU B012

¿Qué haremos hoy?

Bloque 1

Repaso de `group_by()` + `summarise()`

- Varios cálculos a la vez
- Agrupar por más de una variable

Bloque 2

Primeros pasos con ggplot2

- Los principios básicos
- Gráfico de barras
- Histograma

Usamos la base `dotacion_publica.csv`: 600 funcionarios de 8 ministerios.

Antes de partir

```
library(tidyverse)

datos <- read.csv("data/dotacion_publica.csv")
```

> `ggplot2` viene dentro del `tidyverse`: con `library(tidyverse)` ya tienes todo lo de hoy.

Bloque 1

Repaso de `group_by()` y `summarise()`

La idea: dividir, calcular, juntar

1. Dividir

`group_by(ministerio)`

Separa la base en grupos.

2. Calcular

`summarise(...)`

Hace un cálculo en cada grupo.

3. Juntar

Entrega **una fila por grupo**.

Un cálculo por grupo

```
datos %>%
  group_by(calidad_juridica) %>%
  summarise(renta_promedio = mean(renta_bruta))
```

```
## # A tibble: 3 × 2
##   calidad_juridica renta_promedio
##   <chr>                     <dbl>
## 1 Contrata                1546606.
## 2 Honorarios              1351133.
## 3 Planta                  1624616.
```

> A la izquierda del `=` pones el **nombre** que quieres para la columna nueva; a la derecha, el **cálculo**.

Varios cálculos a la vez

Dentro de un mismo `summarise()`, los cálculos van **separados por coma**:

```
datos %>%
  group_by(calidad_juridica) %>%
  summarise(
    n = n(),
    renta_promedio = mean(renta_bruta),
    renta_mediana = median(renta_bruta),
    renta_maxima = max(renta_bruta)
  )
```

```
## # A tibble: 3 × 5
##   calidad_juridica     n renta_promedio renta_mediana renta_maxima
##   <chr>            <int>          <dbl>         <dbl>        <int>
## 1 Contrata           310       1546606.       1381000      4468000
## 2 Honorarios         113       1351133.       1156000      2655000
## 3 Planta             177       1624616.       1297000      3954000
```

Funciones útiles dentro de `summarise()`

Para calcular	Función
Cuántos hay	`n()`
Promedio / mediana	`mean()` / `median()`
Dispersión	`sd()`
Mínimo / máximo	`min()` / `max()`
Proporción (sobre un Sí/No)	`mean(teletrabajo == "Sí")`

Si la variable tiene `NA`, agrega `na.rm = TRUE`: por ejemplo `mean(evaluacion_desempeno, na.rm = TRUE)`.

Con valores perdidos

```
datos %>%
  group_by(calidad_juridica) %>%
  summarise(
    n = n(),
    eval_promedio = mean(evaluacion_desempeno, na.rm = TRUE)
  )
```

```
## # A tibble: 3 × 3
##   calidad_juridica     n eval_promedio
##   <chr>            <int>         <dbl>
## 1 Contrata           310          5.63
## 2 Honorarios         113        NaN
## 3 Planta             177          5.62
```

> Los honorarios no tienen evaluación: todos sus valores son `NA`, por eso el resultado sale `NaN` (no hay nada que promediar).

Agrupar por más de una variable

Basta con poner **otra variable** dentro de `group_by()`:

```
datos %>%
  group_by(calidad_juridica, sexo) %>%
  summarise(
    n = n(),
    renta_promedio = mean(renta_bruta)
  )
```

```
## # A tibble: 6 × 4
## # Groups:   calidad_juridica [3]
##   calidad_juridica sexo          n renta_promedio
##   <chr>            <chr>     <int>          <dbl>
## 1 Contrata         Femenino    176       1478034.
## 2 Contrata         Masculino   134       1636672.
## 3 Honorarios       Femenino     74       1372622.
## 4 Honorarios       Masculino    39       1310359.
## 5 Planta           Femenino     94       1501883.
## 6 Planta           Masculino    83       1763614.
```

¿Cómo se lee?

Con dos variables, R arma **una fila por cada combinación**: Contrata-Femenino, Contrata-Masculino, Honorarios-Femenino, etc.

¿Y ese mensaje de `summarise()` has grouped output...? Es solo un aviso: la tabla queda agrupada por la primera variable. No es un error. Si quieres que se vaya, agrega `.groups = "drop"` dentro de `summarise()`.

Ordenar el resultado con `arrange()`

```
datos %>%
  group_by(ministerio, sexo) %>%
  summarise(
    n = n(),
    renta_promedio = mean(renta_bruta),
    .groups = "drop"
  ) %>%
  arrange(desc(renta_promedio))
```

`arrange()` va al final, después del `summarise()`. `desc()` ordena de mayor a menor.

Errores frecuentes

Falta la coma

Entre un cálculo y otro dentro de `summarise()`.

Los `NA`

Olvidar `na.rm = TRUE` y obtener `NA` en el resultado.

Orden equivocado

Poner `arrange()` **antes** del `summarise()`: ahí aún no existe la columna nueva.

Actividad — Bloque 1

1. Por `calidad_juridica`: cantidad de funcionarios, renta promedio y renta mediana.

2. Por `estamento`: cantidad, renta promedio, desviación estándar, mínimo y máximo de `renta_bruta`.

3. Por `ministerio` y `sexo`: cantidad y renta promedio, ordenado de mayor a menor renta.

4. Desafío. Por `region` y `teletrabajo`: cantidad y evaluación promedio (ignora los `NA`), ordenado de mayor a menor.

Bloque 2

Primeros pasos con ggplot2

Una tabla de 600 filas no se lee

Un gráfico se entiende en segundos

Antes de graficar, pregúntate dos cosas

1. ¿Qué quiero mostrar?

¿Cómo se distribuye algo? ¿Cuántos hay de cada tipo? ¿Cómo se comparan los grupos?

2. ¿Qué tipo de variable tengo?

Categórica (ministerio, sexo) o numérica (renta, edad).

El **tipo de variable** decide el gráfico: numérica → **histograma**; categórica → **barras**.

Dos formas de graficar en R

R base

`hist()`, `plot()`

Rápido para **explorar**. Poco estético.

ggplot2

`ggplot() + geom_...()`

Para **reportes** y presentaciones. Es el que usaremos.

```
hist(datos$renta_bruta)     # R base: sirve para mirar rápido
```

La lógica de ggplot2: por capas

1. Datos

`ggplot(datos)`

¿Qué base?

2. Estética

`aes(x = ...)`

¿Qué variable va en el eje?

3. Geometría

`geom_...()`

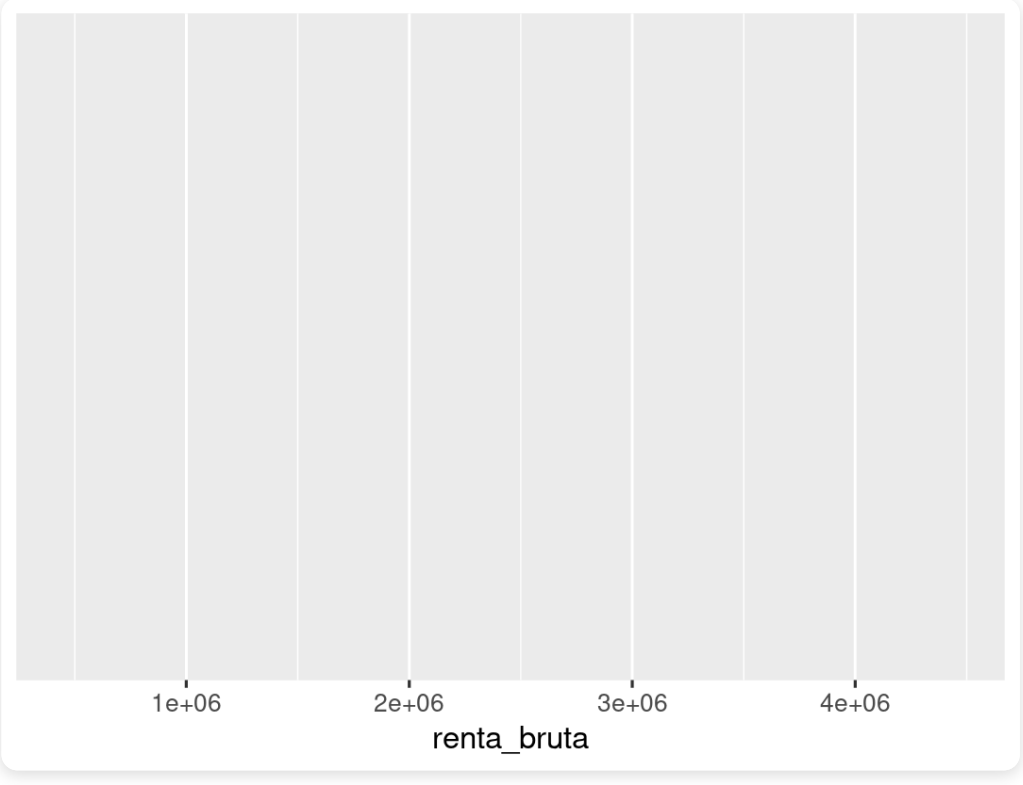
¿Con qué figura?

Las capas se **suman con +**, y el `+` va **al final** de la línea.

Paso 1 y 2: datos y estética... ¿y el gráfico?

```
ggplot(datos, aes(x = renta_bruta))
```

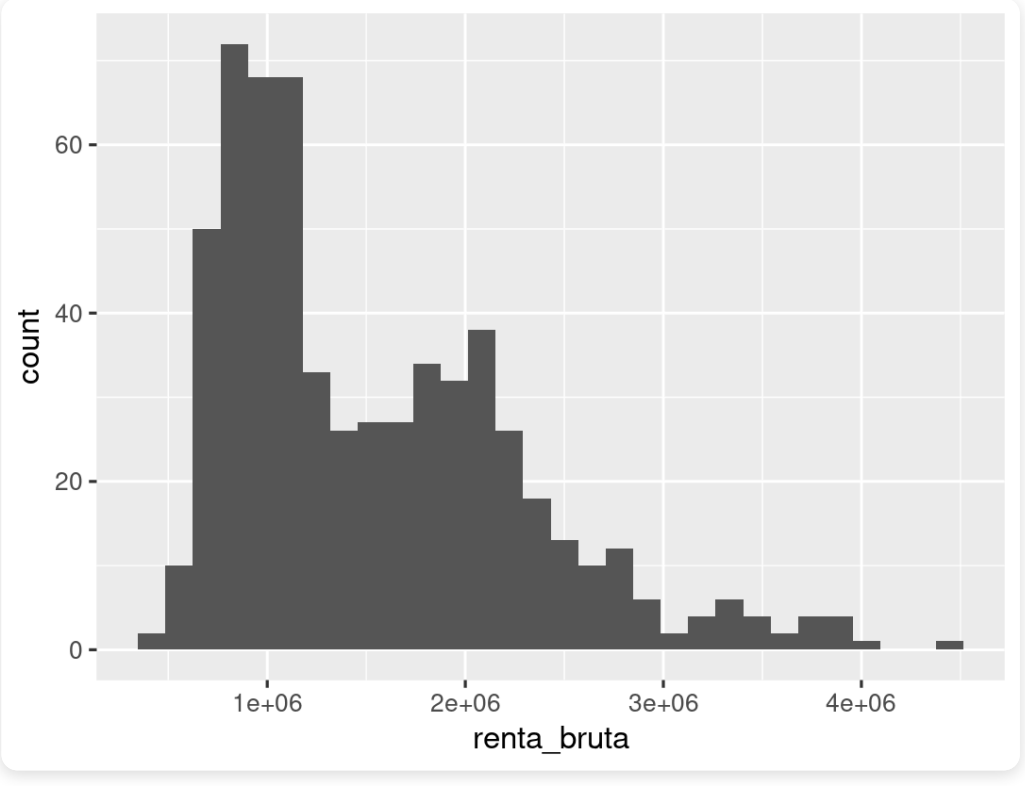
Sale un gráfico **vacío**: ya le dijimos *qué base* y *qué variable*, pero falta decirle **cómo dibujarla**.



Paso 3: agregar la geometría

```
ggplot(datos, aes(x = renta_bruta)) +
  geom_histogram()
```

Con `geom_histogram()` el gráfico aparece. Sin variable en `y`, ggplot2 pone la **frecuencia**: cuántos casos hay en cada tramo.



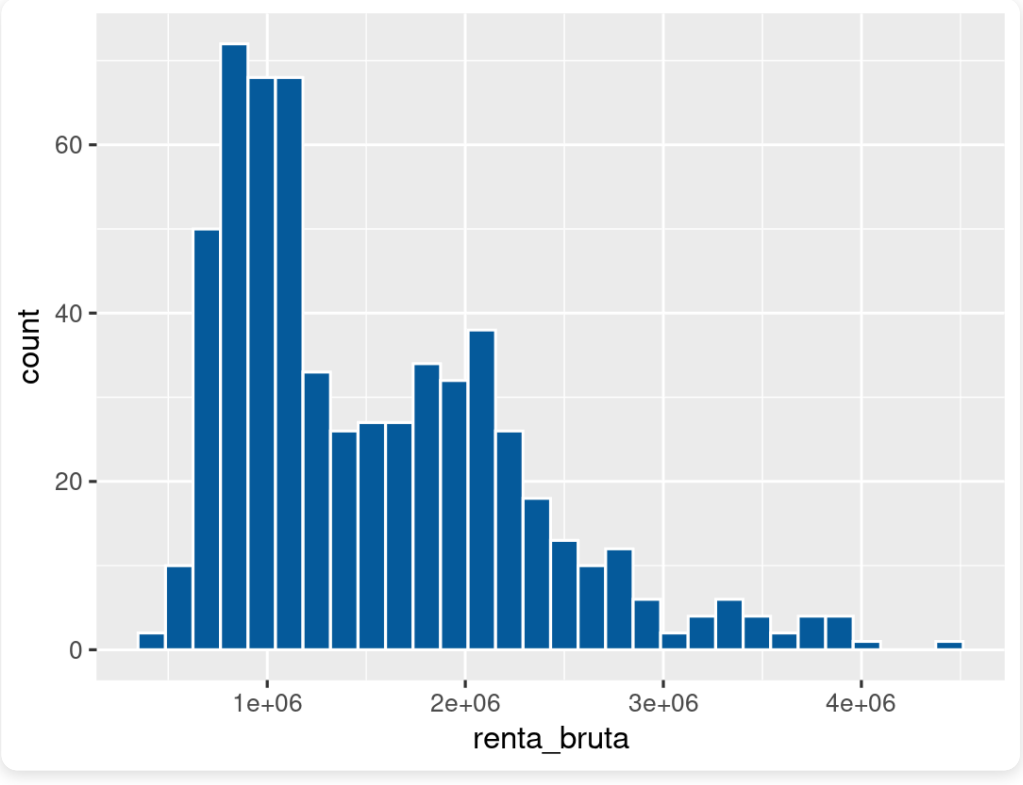
Variable numérica

Histograma

Ajustar el histograma

```
ggplot(datos, aes(x = renta_bruta)) +
  geom_histogram(bins = 30,
                 fill = "#085e9f",
                 color = "white")
```

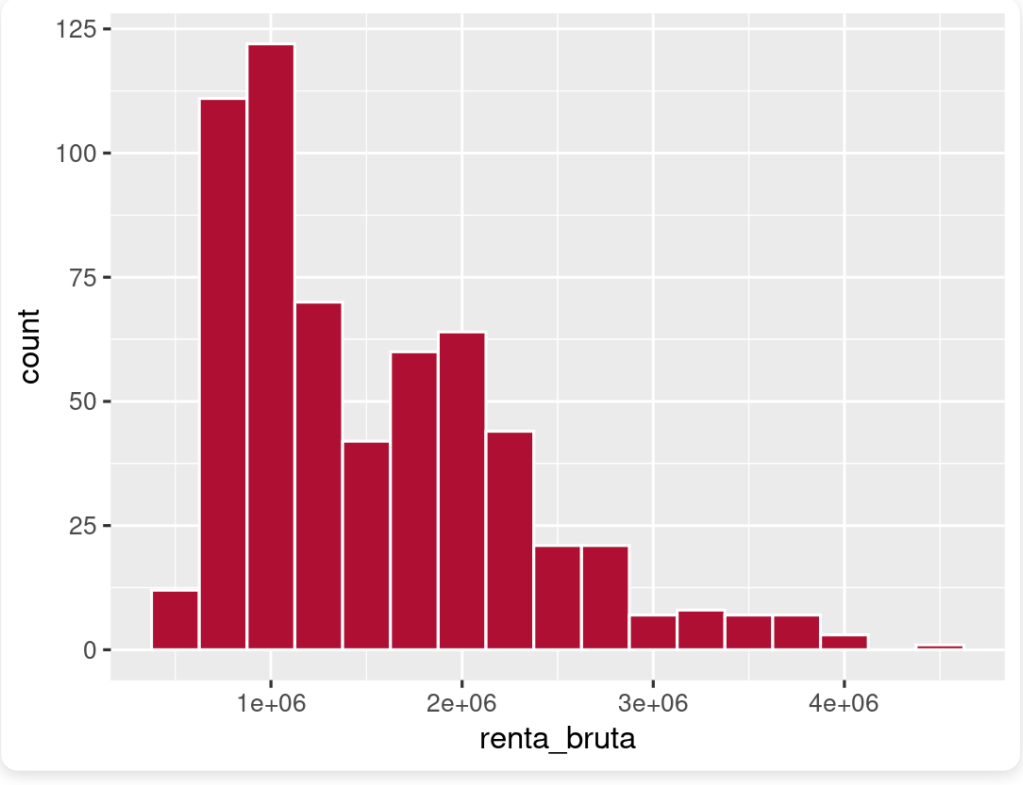
- `bins`: **cuántas** barras
- `binwidth`: **qué ancho** tiene cada una
- `fill`: color de **relleno**
- `color`: color del **borde**



Cambiar el ancho cambia lo que ves

```
ggplot(datos, aes(x = renta_bruta)) +
  geom_histogram(binwidth = 250000,
                 fill = "#b01333",
                 color = "white")
```

Con intervalos de 250.000 pesos se ve mejor la forma.
Prueba varios valores.



Leyendo el histograma

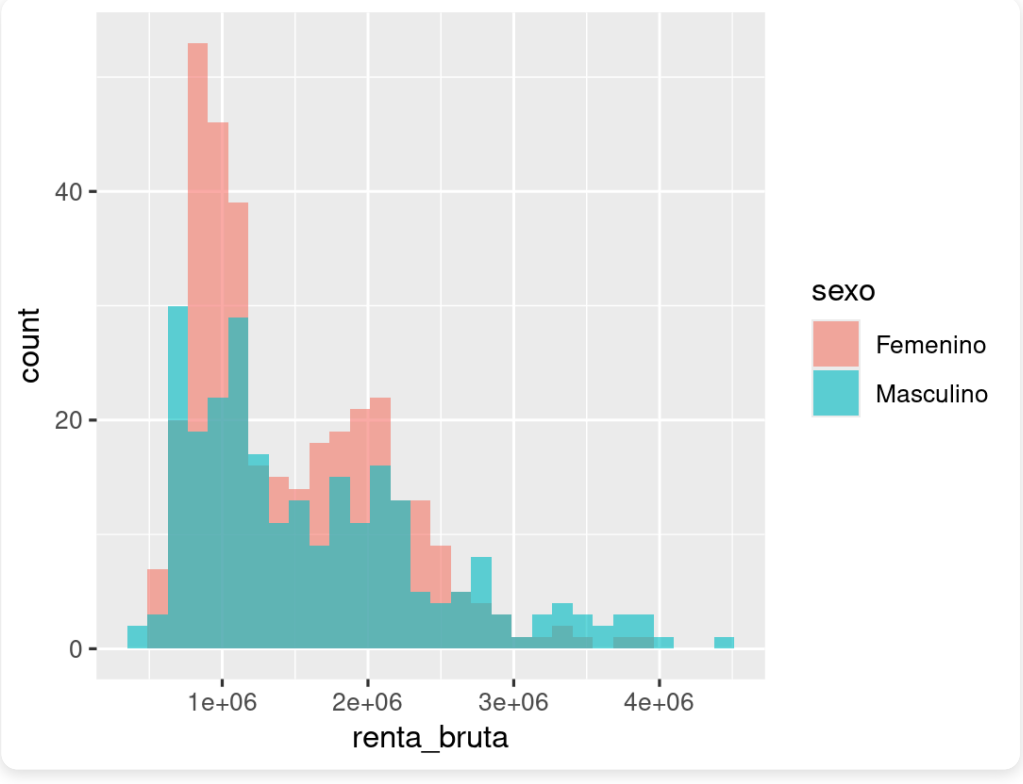
La mayoría de las rentas está en la zona baja y hay una **cola larga hacia la derecha**: pocos sueldos muy altos.

Por eso la **media es mayor que la mediana**: la cola tira el promedio hacia arriba.

Comparar grupos con `fill`

```
ggplot(datos, aes(x = renta_bruta,
                  fill = sexo)) +
  geom_histogram(bins = 30,
                 alpha = 0.6,
                 position = "identity")
```

Si el color **depende de una variable**, va dentro de `aes()`. `alpha` agrega transparencia para ver ambos grupos.



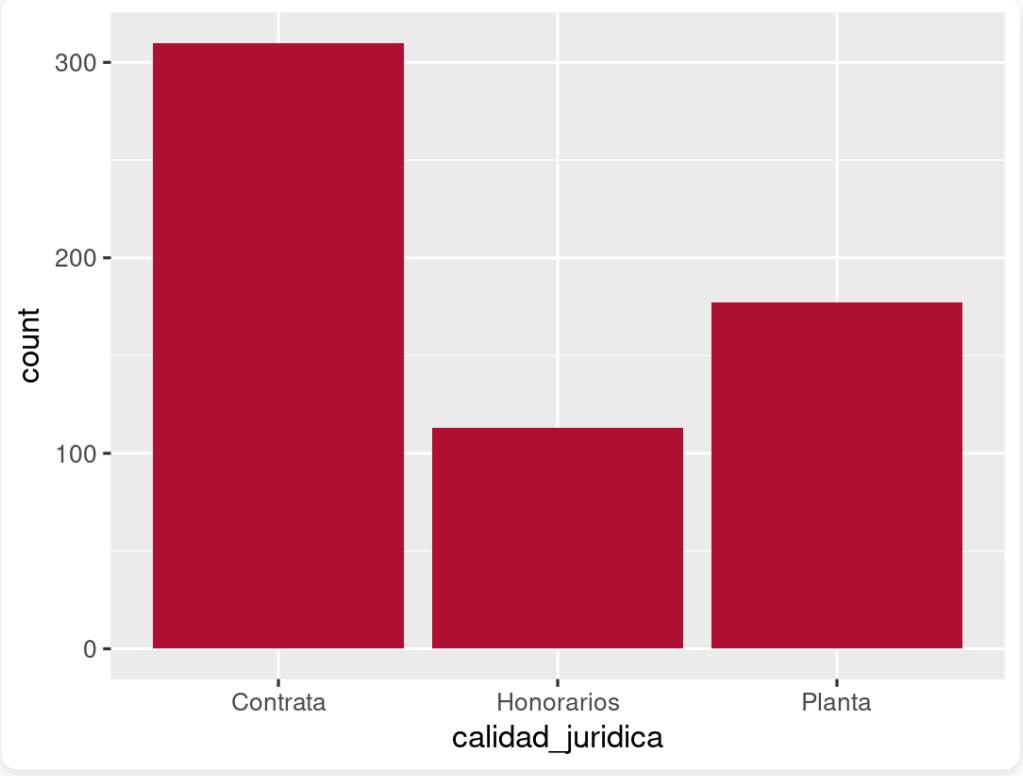
Variable categórica

Gráfico de barras

`geom_bar()`: ¿cuántos hay de cada categoría?

```
ggplot(datos, aes(x = calidad_juridica)) +
  geom_bar(fill = "#b01333")
```

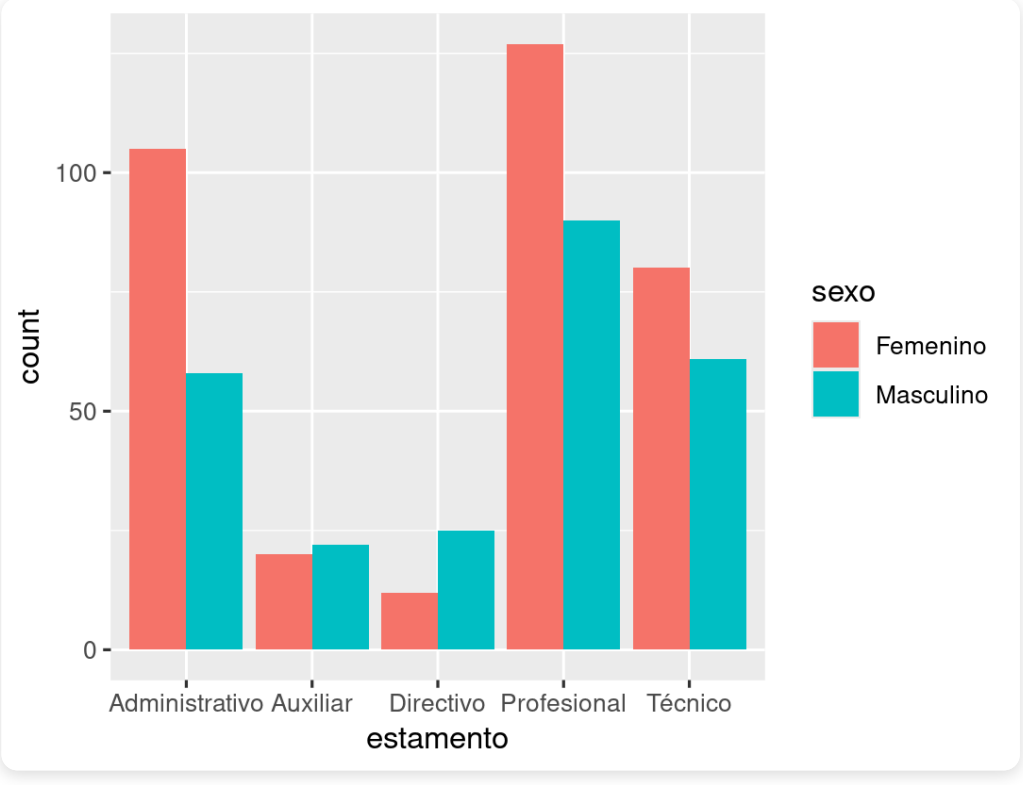
`geom_bar()` **cuenta sola**: tú solo indicas la variable en `x`.



Dos categóricas

```
ggplot(datos, aes(x = estamento, fill = sexo)) +
  geom_bar(position = "dodge")
```

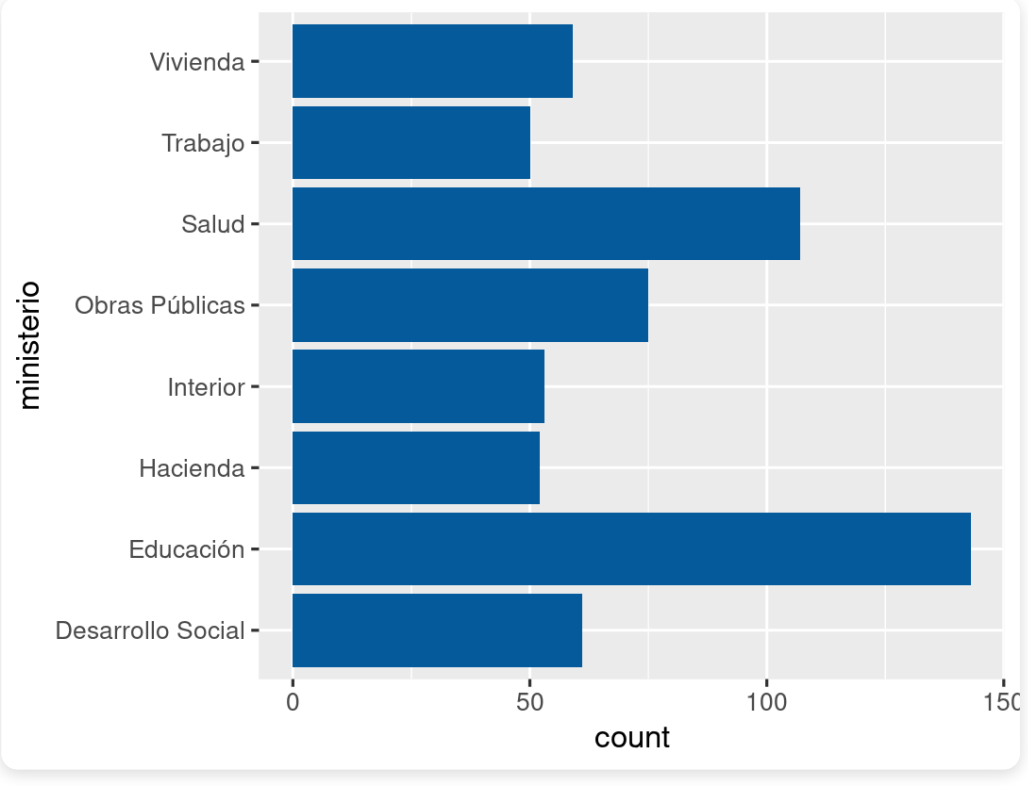
`fill = sexo` divide cada barra por grupo. `position = "dodge"` las pone **una al lado de la otra**.



Nombres largos: `coord_flip()`

```
ggplot(datos, aes(x = ministerio)) +
  geom_bar(fill = "#085e9f") +
  coord_flip()
```

`coord_flip()` **gira** el gráfico para que los nombres se lean bien.



Si algo falla

```
Error: object 'calidad_juridca' not found
→ el nombre de la columna está mal escrito.
```

```
could not find function "ggplot"
→ falta library(tidyverse).
```

También revisa que cada + esté al final de la línea.

Actividad — Bloque 2

5. Histograma de `edad` con intervalos de 5 años (`binwidth = 5`), relleno rojo y borde blanco.

6. Gráfico de **barras** con la cantidad de funcionarios por `region`, en azul (`"#085e9f"`).

7. Barras de `region` divididas por `sexo`, una al lado de la otra, y giradas con `coord_flip()`.

Próxima clase: ggplot2, profundización

Boxplots, dispersión, gráficos de resumen, títulos, temas y

Dudas: fvillarroelr1@docente.uss.cl · Tecnología para la Gestión II · ADPU B012